





Урок 14 (бонусный) Spark и Kubernetes

Запускаем Spark в Kubernetes с помощью Spark Operator

Александр Волынский

Technical Product Manager
ML Platform
VK Cloud Solutions

Для кого

- В первую очередь будет интересно для Data Engineer, Data Scientist
- Для тех, кто разворачивает и поддерживает инфраструктуру для DE и DS команд
- Для всех, кто интересуется большими данными и ролью Kubernetes при работе с данными





Александр Волынский

Technical Product Manager ML Platform, VK Cloud Solutions

- Архитектор VK Cloud Solutions
- Специалист по Big Data
- Участвовал в создании хранилищ данных в «Платформе ОФД», Mail.ru Group (теперь VK), X5 Group и других компаниях
- Энтузиаст использования Kubernetes для построения Data Lake, DWH и ML-платформ в облаках

Коротко o Spark

- Apache Spark is a multi-language engine for executing data engineering, data science, and machine learning on single-node machines or clusters
- Умеет работать с Yarn, Mesos, Kubernetes и в Standalone режиме
- Пришел на смену Hadoop MapReduce
- Чаще всего идет в комплекте с Hadoop кластером



Spark u Kubernetes

- Spark можно запускать в Kubernetes, начиная с версии 2.3 (2018). Production-ready в версии 3.1
- Есть два способа запуска: spark-submit и Kubernetes Operator for Spark
- **Kubernetes Operator for Spark Kubernetes native way** (https://www.lightbend.com/blog/how-to-manage-monitor-spark-on-kubernetes-introduction-spark-submit-kubernetes-operator)
- Spark operator позволяет решить проблемы с доступом к логам, получением текущего статуса и состояния джобы

(https://github.com/GoogleCloudPlatform/spark-on-k8s-operator/blob/master/docs/quick-start-guide.md)



Почему стоит запускать Spark в Kubernetes



Изоляция сред (контейнеризация и dependency management)



Управление ресурсами



Гибкое масштабирование

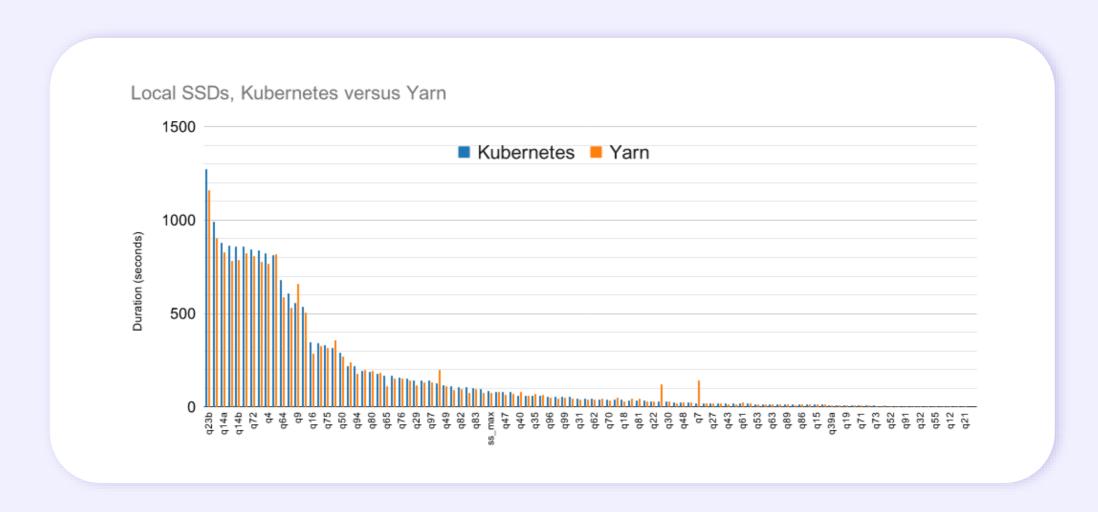


Разделение storage и compute слоёв





Сравнение быстродействия



Yarn в среднем быстрее на 4-5%

https://www.datamechanics.co/blog-post/apache-spark-performance-benchmarks-show-kubernetes-hascaught-up-with-yarn





Этапы

- **01** Запустим k8s кластер
- **02** Установим Spark Operator
- 3апустим стандартную тестовую джобу для проверки работо-способности Spark Operator
- О4 Соберём кастомный образ с нашим приложением
- **05** Запустим приложение, проверим логи, результаты работы



Репозиторий с инструкцией и необходимыми шаблонами

https://github.com/stockblog/webinar_spark_k8s



Итоги

Познакомились со Spark: преимуществами и ограничениями при запуске в K8s 01

- Получили базовые навыки работы со Spark Operator
- 03 Протестировали Spark в Kubernetes
- 04 Собрали собственный Docker образ со Spark приложением
- Протестировали Spark History Server в K8s









Спасибо!

Александр Волынский

Почта: <u>a.volinsky@corp.mail.ru</u>

Моб. тел: +7 (960) 115-76-94

Вконтакте: https://vk.com/volinski



VK Cloud Solutions

Полезные статьи по теме:



Памятка по Spark в Kubernetes



MLops-1. Как развернуть **Kubeflow** в Kubernetes в продакшенварианте



MLops-2. MLflow — это еще один инструмент для построения MLOps, для работы с которым не обязателен Kubernetes

Подписывайтесь на канал t.me/k8s_vk

